

隱私保護資料分析期末專案

參考論文: Personalized Federated Learning for Cross-City Traffic Prediction

一. 研究背景與動機

隨著智慧交通系統的發展，交通流量預測成為城市交通管理中的重要問題。準確的交通預測可以協助交通壅塞預警、路網調度、公共運輸規劃與即時導航系統。然而，交通資料通常具有明顯的時間週期性與空間關聯性，例如早晚尖峰時段的流量變化、相鄰路段之間的交通影響，以及不同城市道路結構造成的資料分布差異。因此，交通預測模型需要同時學習時間模式與空間結構。


在跨城市交通預測任務中，不同城市可能擁有不同規模的感測器數量、道路拓撲與交通型態。部分城市具有大量歷史資料，可以作為 **source cities**；但目標城市 **target city** 可能只有少量可用資料。在這種 **low-resource target city** 的情境下，若直接使用 **target city** 少量資料進行 **fine-tuning**，模型容易產生 **overfitting**，導致在測試資料上的泛化能力不佳。

原始 **pFedCTP** 方法透過 **federated learning** 與 **personalized spatio-temporal modeling** 來學習跨城市知識，並在 **target city** 上進行 **fine-tuning**。然而，原始方法在 **target city fine-tuning** 階段採用固定訓練 **epoch** 的方式，沒有根據 **target city** 的 **validation performance** 自動調整訓練時間。因此，若 **target city** 資料量不足，固定 **epoch fine-tuning** 可能導致訓練不足或過度訓練。

基於上述問題，本專案聚焦於改進 **target city fine-tuning** 階段，希望在不大幅更動原始 **pFedCTP** 架構的前提下，透過 **validation-based fine-tuning**、**regularization** 與多種 **fine-tuning** 策略切換，提升 **target city** 的預測表現與泛化能力。

二. 原始方法簡介

本專案以 **pFedCTP** 作為基礎模型。**pFedCTP** 是一個針對跨城市交通預測設計的 **personalized federated learning** 方法。每個 **client** 對應一個城市，並在 **federated learning** 過程中訓練各自的 **local ST-Net**。整體方法希望從多個 **source cities** 學習可轉移的交通時空表示，再將模型應用於資料稀少的 **target city**。



在 ST-Net 架構中，模型主要包含數個與交通預測相關的模組：

1. TP module

TP module 主要負責學習交通資料中的時間模式，例如早晚尖峰、日週期變化與交通流量的時間趨勢。

2. SS module

SS module 主要負責學習城市道路網路的空間結構，例如不同感測器節點之間的拓撲關係與道路連接特性。

3. ST module

ST module 用於整合 temporal features 與 spatial relationships，使模型能夠捕捉某一路段交通變化與周圍節點之間的相互影響。

4. ST Predictor

ST Predictor 負責根據前面學到的 spatio-temporal representation 產生未來多個 time steps 的交通預測結果。

原始 pFedCTP 在 federated learning 階段會讓 source cities 與 target city 的 client 共同訓練模型，並透過參數聚合與個人化設計學習跨城市共享知識。完成 federated training 後，target city 會使用少量本地資料進行 fine-tuning，最後在 target city 的測試資料上評估預測表現。

然而，原始 target city fine-tuning 階段主要使用固定 epoch 訓練，缺少 validation-based model selection。當 target city 資料量不足時，固定 epoch 設定可能無法適應不同城市的資料特性。因此，本研究將改進重點放在 target city fine-tuning 階段。

三.研究問題

本專案主要探討以下研究問題：

Q1：固定 epoch fine-tuning 是否容易造成 target city overfitting？

原始 pFedCTP 在 target city fine-tuning 時使用固定 target_epochs，例如固定訓練 50 epochs。然而 target city 僅有少量資料時，模型可能在前幾個 epoch 已經達到較佳 validation performance，繼續訓練反而可能使模型過度適應少量 target training data。因此，本研究首先探討是否可以透過 validation loss 監控 fine-tuning 過程，並在 validation loss 不再改善時提前停止訓練。

Q2：加入 regularization 是否能降低 target city fine-tuning 的過擬合？

target city 資料有限時，模型參數在 fine-tuning 過程中可能偏離 federated learning 後得到的 global representation。若偏離過大，模型可能失去從 source cities 學到的跨城市交通知識。因此，本研究進一步加入 parameter regularization，使 target model 在 fine-tuning 時不會距離 fine-tuning 前的模型參數太遠。

Q3：不同 fine-tuning 策略對 target city 預測效能有何影響？

除了 full fine-tuning 之外，本研究也比較 predictor-only、private-module、regularized、early-stopping 等不同 target fine-tuning 策略。不同策略更新的參數範圍不同，可能對少量 target data 有不同程度的適應能力與過擬合風險。因此，本研究設計 ft_mode 參數，使模型能夠切換不同 fine-tuning 策略並進行比較。

Q4：分階段 fine-tuning 是否能比單一步驟 fine-tuning 更穩定？

單純 full fine-tuning 可能太容易過擬合，而 predictor-only fine-tuning 又可能過於保守，無法充分適應 target city。因此，本研究提出 staged regularized early stopping 策略，先讓 prediction head 適應 target city，再進一步調整 private spatio-temporal modules，並搭配 regularization 與 validation early stopping，以期在穩定性與適應能力之間取得平衡。

四. Proposed Method

本研究保留原始 pFedCTP 的 federated learning 與 ST-Net 架構，主要針對 target city fine-tuning 階段進行改進。整體設計包含三個主要部分：Validation-based Early Stopping、Regularized Fine-tuning，以及 Fine-tuning Strategy Switching with Staged Regularized Early Stopping。

4.1 Validation-based Early Stopping

原始 pFedCTP 在 target city fine-tuning 階段使用固定 target_epochs。本研究首先將 target city 的少量資料依照時間順序切分為 train、validation 與 test 三個部分。由於交通資料具有時間序列特性，本研究避免使用 random split，以降低未來時間資訊洩漏到訓練資料中的風險。

資料切分方式如下：

- 前 80% target scarce data 作為 training set
- 中間 10% target scarce data 作為 validation set
- 最後 10% target scarce data 作為 test set

在 fine-tuning 過程中，模型每個 epoch 使用 target train set 更新參數，並在 target validation set 上計算 validation loss。如果 validation loss 連續多個 epoch 沒有改善，則提前停止訓練，並回復到 validation loss 最佳時的模型參數。

此方法的目的不是增加模型複雜度，而是讓 target city fine-tuning 能夠根據 validation performance 自動選擇較合適的訓練 epoch，避免固定 epoch 導致過度訓練。

4.2 Regularized Fine-tuning with Validation

第二個改進是在 validation-based early stopping 的基礎上加入 parameter regularization。其核心想法是：target city 的資料量較少，若 fine-tuning 時讓所有參數自由更新，模型可能過度適應 target training data，並偏離 federated training 後得到的跨城市知識。

因此，本研究在 fine-tuning loss 中加入參數距離限制。模型會先保存 target fine-tuning 前的參數作為 anchor model，接著在 target city fine-tuning 時，限制目前模型參數不要距離 anchor model 太遠。

總損失可表示為：

$$\text{Total Loss} = \text{Prediction Loss} + \lambda \times \text{Regularization Loss}$$

其中 **Prediction Loss** 為模型預測值與真實值之間的誤差，**Regularization Loss** 為目前模型參數與 fine-tuning 前模型參數之間的距離， λ 為 regularization strength。

本研究進一步設計兩個 regularization 控制方式：

1. **reg_exclude_predictor**

若設定為 1，則不對 stPredictor 加入 regularization，使最後的 prediction head 可以更自由地適應 target city。

2. **reg_normalize**

若設定為 1，則將 regularization loss 以參數數量平均，使不同模型規模下的 λ 較容易調整。

在 validation 階段，本研究只使用 prediction loss 作為 early stopping 的依據，而不將 regularization loss 加入 validation loss。這樣可以確保 validation loss 反映的是交通預測能力，而不是模型參數距離。

4.3 Fine-tuning Strategy Switching

第三個改進是設計 ft_mode 參數，使 target city fine-tuning 可以切換不同策略。這樣可以在同一套程式架構下比較不同 fine-tuning 方法對 target city 預測效果的影響。

本研究支援以下 fine-tuning modes：

1. **early_stopping**

所有模型參數都參與 fine-tuning，但使用 validation loss 進行 early stopping 與 best checkpoint selection。

2. **regularized**

在 early stopping 的基礎上加入 parameter regularization，避免 target model 偏離 fine-tuning 前的模型太遠。

3. **predictor_only**

只更新 stPredictor，凍結其他模組。此方法較保守，適合 target city 資料極少的情境。

4. **private_only**

更新與城市個人化較相關的 modules，例如 spatialModel、stPare 與 stPredictor，並凍結其他共享模組。此方法希望保留跨城市共享的交通模式，同時讓城市特定模組適應 target city。

4.4 Staged Regularized Early Stopping

除了上述五種策略，本研究進一步提出一個改良方法：**staged regularized early stopping**。

此方法分為兩個階段：

Stage 1 : Predictor-only Warmup

第一階段只更新 stPredictor，其他模型參數保持凍結。此階段的目的是先讓最後的 prediction head 快速適應 target city 的輸出分布，避免一開始就更新整個模型造成 representation drift。

Stage 2 : Private Modules + Predictor Fine-tuning

第二階段解凍 spatialModel、stPare 與 stPredictor，並加入 parameter regularization 與 validation-based early stopping。此階段允許模型進一步調整 target city 相關的 spatio-temporal representation，但透過 regularization 限制模型不要偏離原本 federated model 太遠。

此 staged 設計的核心想法是：先用較保守的 predictor-only warmup 進行初步適應，再逐步放開較多 target-specific modules，使模型在適應能力與泛化能力之間取得更好的平衡。

五.實驗設計

5.1 Dataset

本研究使用 pFedCTP 原始設定中的交通資料集進行實驗，包含多個城市或交通網路資料來源，例如：

- METR-LA
- PEMS-BAY
- Shenzhen
- Chengdu

其中，source cities 用於 federated learning 階段，target city 則模擬資料稀少的城市。實驗中會指定其中一個城市作為 target city，例如 Shenzhen，並僅使用 target city 前數天資料作為 scarce target data。

Target city scarce data 會依照時間順序切分為：

- Train set：80%
- Validation set：10%
- Test set：10%

此切分方式用於 validation-based fine-tuning 與 final testing。由於交通資料具有時間連續性，本研究採用 chronological split 而非 random split，以避免時間序列資料中的資訊洩漏問題。

本研究主要實驗設定如下：

Experiment Setting	
Batch size	32
Federated rounds	90
Target days	3
GCN layers	1

5.2 Evaluation Metrics

本研究使用交通預測任務中常見的 evaluation metrics 來評估模型表現，包括：

1. Mean Absolute Error, MAE

MAE 衡量預測值與真實值之間的平均絕對誤差。MAE 越低，代表模型平均預測誤差越小。

2. Root Mean Squared Error, RMSE

RMSE 衡量預測誤差平方平均後再開根號的結果。RMSE 對較大的預測錯誤更敏感，因此可以反映模型是否出現較嚴重的預測偏差。

由於本任務為 multi-step traffic forecasting，模型會預測未來多個 time steps。因此，本研究會分別記錄不同 prediction horizons 下的 MAE 與 RMSE，例如 horizon 1 至 horizon 6 的結果，並計算平均 MAE 與平均 RMSE 作為整體表現比較。

此外，本研究也會記錄 early stopping 的 best epoch、validation loss 變化，以及不同 regularization strength 下的結果，以分析模型是否因為過早停止、regularization 過強或過弱而影響最終 performance。

實驗結果表格如下：

Method	RMSE@1	RMSE@2	RMSE@3	RMSE@4	RMSE@5	RMSE@6
Original pFedCTP	2.764	3.255	3.529	3.75	3.939	4.107
Early Stopping	2.192	2.798	3.092	3.303	3.47	3.615
Predictor-only	2.223	2.797	3.088	3.297	3.468	3.618
Private-only	2.213	2.76	3.026	3.219	3.38	3.52
Proposed Staged-Reg-ES	2.264	2.806	3.066	3.245	3.389	3.518

regularized+validation

Method	RMSE@1	RMSE@2	RMSE@3	RMSE@4	RMSE@5	RMSE@6
Regularized + Validation (0.001)	2.187	2.776	3.066	3.276	3.444	3.592
Regularized + Validation (0.01)	2.186	2.775	3.065	3.274	3.443	3.591
Regularized + Validation (0.1)	2.186	2.775	3.065	3.275	3.443	3.591
Regularized + Validation (1)	2.185	2.775	3.065	3.274	3.442	3.589

Method	MAE@1	MAE@2	MAE@3	MAE@4	MAE@5	MAE@6
Original pFedCTP	1.903	2.19	2.333	2.457	2.571	2.679
Early Stopping	1.534	1.892	2.059	2.197	2.314	2.421
Predictor-only	1.542	1.883	2.048	2.184	2.306	2.418
Private-only	1.562	1.879	2.026	2.152	2.264	2.364
Proposed Staged-Reg-ES	1.628	1.941	2.083	2.188	2.279	2.368

regularized+validation

Method	MAE@1	MAE@2	MAE@3	MAE@4	MAE@5	MAE@6
Regularized + Validation (0.001)	1.521	1.864	2.028	2.167	2.288	2.4
Regularized + Validation (0.01)	1.52	1.863	2.027	2.166	2.287	2.398
Regularized + Validation (0.1)	1.52	1.863	2.027	2.166	2.287	2.398
Regularized + Validation (1)	1.52	1.863	2.027	2.166	2.286	2.397